Hoja de Referencia Econometría

Por Marcelo Moreno Porras - Universidad Rey Juan Carlos
The Econometrics Cheat Sheet Project

Conceptos básicos

Definiciones

Econometría: Disciplina de las Ciencias Sociales que tiene como objetivo cuantificar las relaciones entre agentes económicos, contrastar teorías económicas y evaluar e implementar políticas públicas y privadas.
Modelo econométrico: Representación simplificada de la realidad para explicar fenómenos económicos.
Ceteris paribus: Si todos los demás factores relevantes permanecen constantes.

Estructuras de datos

Corte transversal: Muestra recogida en un momento dado en el tiempo, una *foto* estática. El orden no importa.
Series temporales: Observaciones a lo largo del tiempo. El orden sí importa.
Datos de panel: Una serie temporal por cada observación de una sección cruzada.
Secciones transversales agrupadas: Secciones cruzadas de diferentes periodos temporales.

Fases de un modelo econométrico

1. Especificación.
2. Estimación.
3. Validación.
4. Utilización.

Análisis de regresión

Estudiar y predecir el valor medio de una variable (dependiente, y) respecto a unos valores fijos de otras variables (independientes, x). Es muy común usar Mínimos Cuadrados Ordinarios (MCO).

Análisis de correlación

El análisis de correlación no distingue entre variables dependientes e independientes.

- La correlación simple mide el grado de asociación lineal entre dos variables.
$$r = \frac{\text{Cov}(x,y)}{s_x \cdot s_y} = \frac{\sum_{i=1}^n ((x_i-\overline{x})\cdot(y_i-\overline{y}))}{\sqrt{\sum_{i=1}^n (x_i-\overline{x})^2 \cdot \sum_{i=1}^n (y_i-\overline{y})^2}}$$
- La correlación parcial mide el grado de asociación lineal entre dos variables controlando una tercera.

Supuestos y propiedades

Supuestos de MCO

Supuestos **Gauss-Markov**:

1. **Linealidad en parámetros** (y dependencia débil en series temporales): y debe ser una función lineal de β.
2. **Muestreo aleatorio**: La muestra se ha tomado de forma aleatoria (sólo sección cruzada).
3. **No colinealidad perfecta**:
   - No hay variables independientes que sean constantes: $\text{Var}(x_j) \neq 0 \quad \forall j = 1, \ldots, k$
   - No hay una relación lineal exacta entre variables independientes.
4. **Media condicional cero y correlación cero**:
   a. No hay variables relevantes fuera del modelo: $\text{Cov}(x_j, u) = 0 \quad \forall j = 1, \ldots, k \rightarrow$ **exogeneidad débil**.
   b. No hay errores sistemáticos: $\text{E}(u \mid x_1, \ldots, x_k) = \text{E}(u) = 0 \rightarrow$ **exogeneidad estricta** (cumple 4a).
5. **Homocedasticidad**: La variabilidad del término de error es igual para todos los niveles de x: $\text{Var}(u_i \mid x_{1i}, \ldots, x_{ki}) = \sigma^2 \quad \forall i = 1, \ldots, n$
6. **No autocorrelación**: Los errores no contienen información sobre otros errores: $\text{Corr}(u_t, u_s \mid x_1, \ldots, x_k) = 0 \quad \forall t \neq s$
7. **Normalidad**: Los errores son independientes e idénticamente distribuidos: $u \sim \mathcal{N}(0, \sigma^2)$
8. **Tamaño de datos**: El número de observaciones disponibles debe ser mayor a $(k+1)$ parámetros a estimar. (Ya satisfecho bajo situaciones asintóticas)

Propiedades asintóticas de MCO

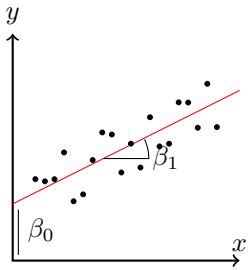
Bajo los supuestos Gauss-Markov y el Teorema Central del Límite (TCL):

- De 1 a 4a: MCO es **consistente**. $\text{plim}(\hat{\beta}_j) = \beta_j$
- De 1 a 4b: MCO es **insesgado**. $\text{E}(\hat{\beta}_j) = \beta_j$
- De 1 a 5: **normalidad asintótica** de estimadores: $\hat{\beta}_j \underset{a}{\sim} \mathcal{N}(\beta_j, \text{Var}(\hat{\beta}_j))$
- De 1 a 6: **estimador insesgado** de σ^2. $\text{E}(\hat{\sigma}^2) = \sigma^2$
- De 1 a 6: MCO es MELI (Mejor Estimador Lineal Insesgado, BLUE en inglés) ó **eficiente**.
- De 1 a 7: contrastes de hipótesis e intervalos de confianza son fiables.

Mínimos Cuadrados Ordinarios

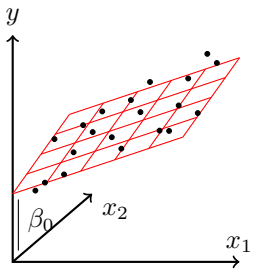
Objetivo: Minimizar Suma de Residuos Cuadrados: $\min \sum_{i=1}^n \hat{u}_i^2$, donde $\hat{u}_i = y_i - \hat{y}_i$

Modelo de regresión simple



Ecuación:
$$y_i = \beta_0 + \beta_1 x_i + u_i$$
Estimación:
$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$
donde:
$$\hat{\beta}_0 = \overline{y} - \hat{\beta}_1 \overline{x}$$
$$\hat{\beta}_1 = \frac{\text{Cov}(y,x)}{\text{Var}(x)}$$

Modelo de regresión múltiple



Ecuación:
$$y_i = \beta_0 + \beta_1 x_{1i} + \cdots + \beta_k x_{ki} + u_i$$
Estimación:
$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \cdots + \hat{\beta}_k x_{ki}$$
donde:
$$\hat{\beta}_0 = \overline{y} - \hat{\beta}_1 \overline{x}_1 - \cdots - \hat{\beta}_k \overline{x}_k$$
$$\hat{\beta}_j = \frac{\text{Cov}(y, \text{resid}\, x_j)}{\text{Var}(\text{resid}\, x_j)}$$
Matriz: $\hat{\beta} = (X^\top X)^{-1}(X^\top y)$

Interpretación de coeficientes

Modelo	Dependiente	Independ.	Interpretación β_1
Nivel-nivel	y	x	$\Delta y = \beta_1 \Delta x$
Nivel-log	y	$\log(x)$	$\Delta y \approx (\beta_1/100)(\%\Delta x)$
Log-nivel	$\log(y)$	x	$\%\Delta y \approx (100\beta_1)\Delta x$
Log-log	$\log(y)$	$\log(x)$	$\%\Delta y \approx \beta_1(\%\Delta x)$
Cuadrático	y	$x + x^2$	$\Delta y \approx (\beta_1 + 2\beta_2 x)\Delta x$

Medidas de error

Suma de Resid. Cuad.: $\text{SRC} = \sum_{i=1}^n \hat{u}_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$
Suma Explicada de Cuadrados: $\text{SEC} = \sum_{i=1}^n (\hat{y}_i - \overline{y})^2$
Suma Tot. de Cuad.: $\text{STC} = \text{SEC} + \text{SRC} = \sum_{i=1}^n (y_i - \overline{y})^2$
Error Estándar de la Regresión: $\hat{\sigma} = \sqrt{\frac{\text{SRC}}{n-k-1}}$
Error Estándar de $\hat{\beta}$: $\text{ee}(\hat{\beta}) = \sqrt{\text{diag}(\hat{\sigma}^2 \cdot (X^\top X)^{-1})}$
Raíz del Error Cuad. Medio: $\text{RECM} = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}}$
Error Medio Absoluto: $\text{EMA} = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{n}$
Porcentaje Error Medio Abs.: $\text{PEMA} = \frac{\sum_{i=1}^n |\hat{u}_i / y_i|}{n} \cdot 100$

R-cuadrado

Mide la **bondad del ajuste**, cómo la regresión se ajusta a los datos:

$$R^2 = \frac{\text{SEC}}{\text{STC}} = 1 - \frac{\text{SRC}}{\text{STC}}$$

- Mide el **porcentaje de variación** en y que es linealmente **explicado** por variaciones de las x.
- Toma valores **entre 0** (no hay explicación lineal) **y 1** (explicación total).

Cuando el número de regresores aumenta, el R-cuadrado también, independientemente de si las nuevas variables son relevantes o no. Para resolver este problema, hay un **R-cuadrado ajustado** por grados de libertad (o corregido):

$$\overline{R}^2 = 1 - \frac{n-1}{n-k-1} \cdot \frac{\text{SRC}}{\text{STC}} = 1 - \frac{n-1}{n-k-1} \cdot (1 - R^2)$$

Para muestras grandes: $\overline{R}^2 \approx R^2$

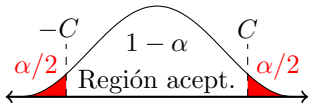
Contrastes de hipótesis

Definiciones

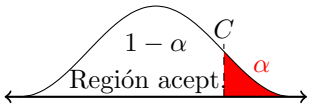
Regla diseñada para determinar, a partir de una muestra, **si existe evidencia para rechazar una hipótesis** formulada sobre uno o más parámetros poblacionales. Elementos:

- **Hipótesis nula** (H_0): Hipótesis a contrastar.
- **Hipótesis alternativa** (H_1): Hipótesis que no puede rechazarse si H_0 es rechazada.
- **Estadístico de contraste**: Variable aleatoria cuya distribución de probabilidad es conocida bajo H_0.
- **Valor crítico** (C): Valor contra el cual se compara el estadístico de contraste para determinar si se rechaza o no H_0. Determina la frontera entre la región de aceptación y la de rechazo de H_0.
- **Nivel de significación** (α): Probabilidad de rechazar H_0 siendo cierta (Error Tipo I). Elegido por quien conduce el contraste. Usualmente 10%, 5% ó 1%.
- **p-valor**: Nivel de significación más bajo para el cual se puede rechazar H_0.

Dos colas. Distrib. H_0



Una cola. Distrib. H_0



Si p-valor $< \alpha$, existe evidencia para rechazar H_0, es decir, existe evidencia a favor de H_1.

Contrastes individuales

Prueba si un parámetro es significativamente diferente de un cierto valor, ϑ.

- $H_0 : \beta_j = \vartheta$
- $H_1 : \beta_j \neq \vartheta$

$$\text{Bajo } H_0: \quad t = \frac{\hat{\beta}_j - \vartheta}{\text{ee}(\hat{\beta}_j)} \sim t_{n-k-1}$$

Si $|t| > |t_{n-k-1,\alpha/2}|$, existe evidencia para rechazar H_0.

Contraste de significación individual: Prueba si un parámetro es **significativamente distinto de cero**.

- $H_0 : \beta_j = 0$
- $H_1 : \beta_j \neq 0$

$$\text{Bajo } H_0: \quad t = \frac{\hat{\beta}_j}{\text{ee}(\hat{\beta}_j)} \sim t_{n-k-1}$$

Si $|t| > |t_{n-k-1,\alpha/2}|$, existe evidencia para rechazar H_0.

Contraste F

Prueba simultáneamente múltiples hipótesis (lineales) sobre los parámetros. Hace uso de un modelo no restringido y uno restringido:

- **Modelo no restringido**: Modelo donde se quiere probar la hipótesis.
- **Modelo restringido**: Modelo donde se ha impuesto la hipótesis.

Entonces, viendo los errores, hay:

- $\textbf{SRC}_{\textbf{NR}}$: SRC del modelo no restringido.
- $\textbf{SRC}_{\textbf{R}}$: SRC del modelo restringido.

$$\text{Bajo } H_0: \quad F = \frac{\text{SRC}_\text{R} - \text{SRC}_\text{NR}}{\text{SRC}_\text{NR}} \cdot \frac{n-k-1}{q} \sim F_{q,n-k-1}$$

donde k es el número de parámetros del modelo no restringido (excluyendo la constante) y q es el número de hipótesis lineales a probar.

Si $F > F_{q,n-k-1}$, existe evidencia para rechazar H_0.

Contraste de significación global: Prueba si todos los parámetros asociados a las x's son **simultáneamente cero**.

- $H_0 : \beta_1 = \beta_2 = \cdots = \beta_k = 0$
- $H_1 : \beta_1 \neq 0$ y/o $\beta_2 \neq 0 \ldots$ y/o $\beta_k \neq 0$

Simplificando la fórmula para el estadístico F:

$$\text{Bajo } H_0: \quad F = \frac{R^2}{1-R^2} \cdot \frac{n-k-1}{k} \sim F_{k,n-k-1}$$

Si $F > F_{k,n-k-1}$, existe evidencia para rechazar H_0.

Intervalos de confianza

El intervalo de confianza al nivel de confianza $(1-\alpha)$:

$$\hat{\beta}_j \pm t_{n-k-1,\alpha/2} \cdot \text{ee}(\hat{\beta}_j)$$

Variables ficticias

Las variables ficticias (o binarias) son usadas para recoger información cualitativa: sexo, estado civil, país, etc.

- Toman **valor 1** en una categoría dada y **0 en el resto**.
- Se usan para analizar y modelar **cambios estructurales** en los parámetros.

Si una variable cualitativa tiene m categorías, sólo hay que incluir $(m-1)$ variables ficticias en un modelo con término constante (incluir m si el modelo no tiene término constante).

Cambio estructural

El cambio estructural se refiere a los cambios en los valores de los parámetros del modelo producidos por el efecto de diferentes sub-poblaciones. El cambio estructural se puede incluir en el modelo a través de variables ficticias.

La ubicación de las variables ficticias (D) es importante:

- **En la constante** (efecto aditivo): Representa la diferencia media entre los valores producidos por el cambio estructural.

$$y = \beta_0 + \delta_1 D + \beta_1 x_1 + u$$

- **En la pendiente** (efecto multiplicativo): Representa la diferencia en el efecto (pendiente) entre los valores producidos por el cambio estructural.

$$y = \beta_0 + \beta_1 x_1 + \delta_1 D \cdot x_1 + u$$

Contraste de Chow para cambio estructural. Prueba la existencia de cambio estructural en todos los parámetros del modelo. Es una expresión particular del contraste F, donde H_0: No hay cambio estructural (todos $\delta = 0$).

Cambios de escala

Cambios en las **unidades de medida** de las variables:

- **Endógena**: $y^* = y \cdot \lambda \rightarrow \beta_j^* = \beta_j \cdot \lambda \quad \forall j = 0, \ldots, k$
- **Exógena**: $x_j^* = x_j \cdot \lambda \rightarrow \beta_j^* = \beta_j / \lambda$
- Endógena y exógena **a la vez**: $y^* = y \cdot \lambda$ y $x_j^* = x_j \cdot \lambda \rightarrow \beta_0^* = \beta_0 \cdot \lambda$; $\beta_j^* = \beta_j$.

Cambios de origen

Cambios en el **origen de medida** de las variables sólo afectan al término constante del modelo:

- **Endógena**: $y^* = y + \lambda \rightarrow \beta_0^* = \beta_0 + \lambda$
- **Exógena**: $x_j^* = x_j + \lambda \rightarrow \beta_0^* = \beta_0 - \lambda\beta_j$

Multicolinealidad

- **Multicolinealidad perfecta**: Hay variables independientes que son constantes y/o hay una relación lineal exacta entre variables independientes. Se **incumple el tercer (3) supuesto** de MCO.
- **Multicolinealidad aproximada**: Hay variables independientes que son aproximadamente constantes y/o hay una relación lineal aproximada entre variables independientes. **No se incumple ningún supuesto** de MCO, pero hay efectos.

Consecuencias

- **Multicolinealidad perfecta**: El sistema de ecuaciones de MCO no puede resolverse (infinitas soluciones).
- **Multicolinealidad aproximada**
  - Pequeñas variaciones en la muestra producen grandes variaciones en las estimaciones de MCO.
  - La varianza de los estimadores MCO de las x's que son colineales aumenta, la inferencia de los parámetros es afectada (intervalo de confianza grande).

Detección

- **Análisis de correlación**: Buscar altas correlaciones entre variables independientes, $|r| > 0.7$.
- **Factor de Inflación de la Varianza (VIF)**: Indica el incremento en $\text{Var}(\hat{\beta}_j)$ debido a la multicolinealidad.

$$\text{VIF}(\hat{\beta}_j) = \frac{1}{1-R_j^2}$$

  donde R_j^2 denota el R-cuadrado de una regresión entre x_j y todas las otras x.
  - Valores entre 4 y 10: Pueden existir problemas de multicolinealidad.
  - Valores > 10: Existen problemas de multicolinealidad.

Una característica típica de la multicolinealidad es que los coeficientes de regresión del modelo no son individualmente significativos (por las altas varianzas), pero sí que son conjuntamente significativos.

Corrección

- Eliminar una de las variables colineales.
- Realizar análisis factorial(u otra técnica de reducción de dimensiones) en las variables colineales.
- Interpretar los coeficientes con multicolinealidad conjuntamente.

Heterocedasticidad

El término de error u_i no tiene una varianza constante condicionada a las variables explicativas:

$$\text{Var}(u_i \mid x_{1i}, \ldots, x_{ki}) = \sigma_i^2 \neq \sigma^2$$

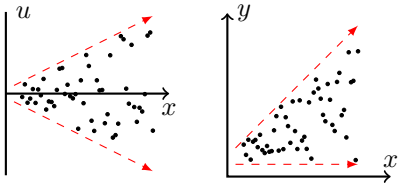
Se **incumple el quinto (5) supuesto** de MCO.

Consecuencias

- Estimadores MCO son consistentes.
- Estimadores MCO son insesgados.
- MCO ya **no es eficiente**, pero sigue siendo ELI (Estimador Lineal Insesgado).
- La **estimación de la varianza** de los estimadores es **sesgada**: La construcción de intervalos de confianza y contraste de hipótesis no son fiables.

Detección

- **Gráficos**: Identificar patrones de dispersión en x vs. u ó x vs. y.



- **Contrastes**: White, Bartlett, Breusch-Pagan, etc. Generalmente, H_0: No heterocedasticidad.

Corrección

- Usar MCO con un estimador de la matriz de varianzas-covarianzas robusto a la heterocedasticidad (HC), por ejemplo, la propuesta de White.
- Si la estructura de la varianza es conocida, usar Mínimos Cuadrados Ponderados (MCP) o Mínimos Cuadrados Generalizados (MCG):
  - Suponiendo que $\text{Var}(u_i) = \sigma^2 \cdot x_i$, dividir las variables del modelo entre la raíz cuadrada de x_i y aplicar MCO.
  - Suponiendo que $\text{Var}(u_i) = \sigma^2 \cdot x_i^2$, dividir las variables del modelo entre x_i (la raíz cuadrada de x_i^2) y aplicar MCO.
- Si la estructura de la varianza es desconocida, hacer uso de Mínimos Cuadrados Ponderados Factibles (MCPF), que estima una posible varianza, divide las variables del modelo entre ella y entonces aplica MCO.
- Nueva especificación del modelo, por ejemplo, transformación logarítmica (reduce la varianza).

Autocorrelación

Los términos de error u_t y u_s están correlacionados a lo largo de distintos periodos temporales, condicionalmente a las variables explicativas:

$$\text{Corr}(u_t, u_s \mid x_1, \ldots, x_k) \neq 0 \quad \exists t \neq s$$

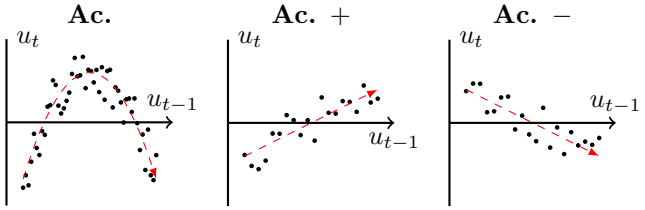
El contexto "natural" de este fenómeno son las series temporales. Se **incumple el sexto (6) supuesto** de MCO.

Consecuencias

- Estimadores MCO son consistentes.
- Estimadores MCO son insesgados.
- MCO ya **no es eficiente**, pero sigue siendo ELI (Estimador Lineal Insesgado).
- La **estimación de la varianza** de los estimadores es **sesgada**: la construcción de intervalos de confianza y contraste de hipótesis no son fiables.

Detección

- **Gráficos**: Identificar patrones de dispersión en gráficos u_{t-1} vs. u_t o hacer uso del correlograma.



- **Contrastes**: Durbin-Watson, Breusch-Godfrey, etc. Generalmente, H_0: No autocorrelación.

Corrección

- Usar MCO con un estimador de la matriz de varianzas-covarianzas robusto a la heterocedasticidad y autocorrelación (HAC), por ejemplo, la propuesta de Newey-West.
- Usar Mínimos Cuadrados Generalizados. Suponiendo $y_t = \beta_0 + \beta_1 x_t + u_t$, con $u_t = \rho u_{t-1} + \varepsilon_t$, donde $|\rho| < 1$ y ε_t es ruido blanco.
  - Si ρ es conocido, crear un modelo cuasi-diferenciado donde ε_t es ruido blanco y estimarlo por MCO.
  - Si ρ es desconocido, estimarlo, por ejemplo, por el método de Cochrane-Orcutt, crear un modelo cuasi-diferenciado donde ε_t es ruido blanco y estimarlo por MCO.