# Hoja de Referencia Econometría

Por Marcelo Moreno Porras - Universidad Rey Juan Carlos
The Econometrics Cheat Sheet Project

## Conceptos básicos

### Definiciones

**Econometría**: Disciplina de las Ciencias Sociales que tiene como objetivo cuantificar las relaciones entre agentes económicos, contrastar teorías económicas y evaluar e implementar políticas públicas y privadas.
**Modelo econométrico**: Representación simplificada de la realidad para explicar fenómenos económicos.
***Ceteris paribus***: Si todos los demás factores relevantes permanecen constantes.

### Estructuras de datos

**Corte transversal**: Muestra recogida en un momento dado en el tiempo, una *foto* estática. El orden no importa.
**Series temporales**: Observaciones a lo largo del tiempo. El orden sí importa.
**Datos de panel**: Una serie temporal por cada observación de una sección cruzada.
**Secciones transversales agrupadas**: Secciones cruzadas de diferentes periodos temporales.

### Fases de un modelo econométrico

1. Especificación.
2. Estimación.
3. Validación.
4. Utilización.

### Análisis de regresión

Estudiar y predecir el valor medio de una variable (dependiente, $y$) respecto a unos valores fijos de otras variables (independientes, $x$). Es muy común usar Mínimos Cuadrados Ordinarios (MCO).

### Análisis de correlación

El análisis de correlación no distingue entre variables dependientes e independientes.

- La correlación simple mide el grado de asociación lineal entre dos variables.
$$r = \frac{\text{Cov}(x,y)}{s_x \cdot s_y} = \frac{\sum_{i=1}^{n}((x_i-\overline{x})\cdot(y_i-\overline{y}))}{\sqrt{\sum_{i=1}^{n}(x_i-\overline{x})^2 \cdot \sum_{i=1}^{n}(y_i-\overline{y})^2}}$$
- La correlación parcial mide el grado de asociación lineal entre dos variables controlando una tercera.

## Supuestos y propiedades

### Supuestos de MCO

Supuestos **Gauss-Markov**:

1. **Linealidad en parámetros**: $y$ debe ser una función lineal de los $\beta$'s.
2. **Muestreo aleatorio**: La muestra se ha tomado de forma aleatoria (sólo sección cruzada).
3. **No colinealidad perfecta**:
   - No hay variables independientes que sean constantes: $\text{Var}(x_j) \neq 0 \quad \forall j = 1, \ldots, k$
   - No hay una relación lineal exacta entre variables independientes.
4. **Media condicional cero y correlación cero**:
   a. No hay variables relevantes fuera del modelo: $\text{Cov}(x_j, u) = 0 \quad \forall j = 1, \ldots, k \rightarrow$ **exogeneidad**
   b. No hay errores sistemáticos: $\text{E}(u \mid x_1, \ldots, x_k) = \text{E}(u) = 0$ $\rightarrow$ **exogeneidad estricta** (cumple 4a)
5. **Homocedasticidad**: La variabilidad del término de error es igual para todos los niveles de $x$: $\text{Var}(u_i \mid x_{1i}, \ldots, x_{ki}) = \sigma^2 \quad \forall i = 1, \ldots, n$
6. **No autocorrelación**: Los errores no contienen información sobre otros errores: $\text{Corr}(u_t, u_s \mid x_1, \ldots, x_k) = 0 \quad \forall t \neq s$
7. **Normalidad**: Los errores son independientes e idénticamente distribuidos: $u \overset{iid}{\sim} \mathcal{N}(0, \sigma^2)$
8. **Tamaño de datos**: El número de observaciones disponibles debe ser mayor a $(k+1)$ parámetros a estimar.

### Propiedades asintóticas de MCO

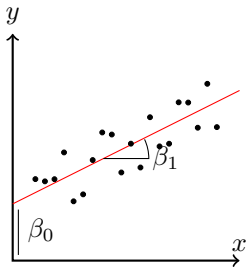
Bajo los supuestos Gauss-Markov y el Teorema Central del Límite (TCL):

- De 1 a 4a: MCO es **consistente**: $\text{plim}(\hat{\beta}_j) = \beta_j$
- De 1 a 4b: MCO es **insesgado**: $\text{E}(\hat{\beta}_j) = \beta_j$
- De 1 a 5: **normalidad asintótica** de estimadores: $\hat{\beta}_j \underset{a}{\sim} \mathcal{N}(\beta_j, \text{Var}(\hat{\beta}_j))$
- De 1 a 6: **estimador insesgado** de $\sigma^2$: $\text{E}(\hat{\sigma}^2) = \sigma^2$
- De 1 a 6: MCO es MELI (Mejor Estimador Lineal Insesgado, BLUE en inglés) ó **eficiente**.
- De 1 a 7: contrastes de hipótesis e intervalos de confianza son fiables.

## Mínimos Cuadrados Ordinarios

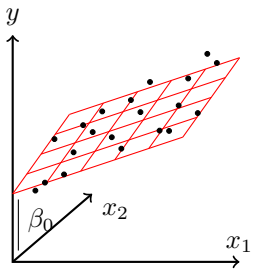
**Objetivo**: Minimizar Suma de Residuos Cuadrados: $\min \sum_{i=1}^{n} \hat{u}_i^2$, donde $\hat{u}_i = y_i - \hat{y}_i$

### Modelo de regresión simple




Ecuación:
$$y_i = \beta_0 + \beta_1 x_i + u_i$$
Estimación:
$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$
donde:
$$\hat{\beta}_0 = \overline{y} - \hat{\beta}_1 \overline{x}$$
$$\hat{\beta}_1 = \frac{\text{Cov}(y,x)}{\text{Var}(x)}$$

### Modelo de regresión múltiple




Ecuación:
$$y_i = \beta_0 + \beta_1 x_{1i} + \cdots + \beta_k x_{ki} + u_i$$
Estimación:
$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \cdots + \hat{\beta}_k x_{ki}$$
donde:
$$\hat{\beta}_0 = \overline{y} - \hat{\beta}_1 \overline{x}_1 - \cdots - \hat{\beta}_k \overline{x}_k$$
$$\hat{\beta}_j = \frac{\text{Cov}(y, \tilde{x}_j)}{\text{Var}(\tilde{x}_j)}$$
Matriz: $\hat{\beta} = (X^\top X)^{-1}(X^\top y)$

### Interpretación de coeficientes

| Modelo | Dependiente | Independ. | Interpretación $\beta_1$ |
|---|---|---|---|
| Nivel-nivel | $y$ | $x$ | $\Delta y = \beta_1 \Delta x$ |
| Nivel-log | $y$ | $\log(x)$ | $\Delta y \approx (\beta_1/100)(\%\Delta x)$ |
| Log-nivel | $\log(y)$ | $x$ | $\%\Delta y \approx (100\beta_1)\Delta x$ |
| Log-log | $\log(y)$ | $\log(x)$ | $\%\Delta y \approx \beta_1(\%\Delta x)$ |
| Cuadrático | $y$ | $x + x^2$ | $\Delta y \approx (\beta_1 + 2\beta_2 x)\Delta x$ |

### Medidas de error

Suma de Resid. Cuad.: $\text{SRC} = \sum_{i=1}^{n} \hat{u}_i^2 = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2$
Suma Explicada de Cuadrados: $\text{SEC} = \sum_{i=1}^{n}(\hat{y}_i - \overline{y})^2$
Suma Tot. de Cuad.: $\text{STC} = \text{SEC} + \text{SRC} = \sum_{i=1}^{n}(y_i - \overline{y})^2$
Error Estándar de la Regresión: $\hat{\sigma} = \sqrt{\frac{\text{SRC}}{n-k-1}}$
Error Estándar de $\hat{\beta}$: $\text{ee}(\hat{\beta}) = \sqrt{\text{diag}(\hat{\sigma}^2 \cdot (X^\top X)^{-1})}$
Raíz del Error Cuad. Medio: $\text{RECM} = \sqrt{\frac{\text{SRC}}{n}}$
Error Medio Absoluto: $\text{EMA} = \frac{1}{n}\sum_{i=1}^{n}|\hat{u}_i|$
Porcentaje Error Medio Absoluto: $\text{PEMA} = \frac{100}{n}\sum_{i=1}^{n}|\frac{\hat{u}_i}{y_i}|$

# R-cuadrado

Mide la **bondad del ajuste**, cómo la regresión se ajusta a los datos:

$$R^2 = \frac{\text{SEC}}{\text{STC}} = 1 - \frac{\text{SRC}}{\text{STC}}$$

- Mide el **porcentaje de variación** en $y$ que es linealmente **explicado** por variaciones de las $x$.
- Toma valores **entre 0** (no hay explicación lineal) **y 1** (explicación total).

Cuando el número de regresores aumenta, el R-cuadrado también, independientemente de si las nuevas variables son relevantes o no. Para resolver este problema, hay un **R-cuadrado ajustado** por grados de libertad (o corregido):

$$\overline{R}^2 = 1 - \frac{n-1}{n-k-1} \cdot \frac{\text{SRC}}{\text{STC}} = 1 - \frac{n-1}{n-k-1} \cdot (1 - R^2)$$

Para muestras grandes: $\overline{R}^2 \approx R^2$

# Contrastes de hipótesis

## Definiciones

Regla diseñada para determinar, a partir de una muestra, **si existe evidencia para rechazar una hipótesis** formulada sobre uno o más parámetros poblacionales. Elementos:

- **Hipótesis nula** ($H_0$): Hipótesis a contrastar.
- **Hipótesis alternativa** ($H_1$): Hipótesis que no puede rechazarse si $H_0$ es rechazada.
- **Estadístico de contraste**: Variable aleatoria cuya distribución de probabilidad es conocida bajo $H_0$.
- **Valor crítico** ($C$): Valor contra el cual se compara el estadístico de contraste para determinar si se rechaza o no $H_0$. Determina la frontera entre la región de no rechazo y de rechazo de $H_0$.
- **Nivel de significación** ($\alpha$): Probabilidad de rechazar $H_0$ siendo cierta (Error Tipo I). Elegido por quien conduce el contraste. Usualmente 10%, 5% ó 1%.
- **p-valor**: Nivel de significación más bajo para el cual se puede rechazar $H_0$.

Test de dos colas, distribución $H_0$




Test de una cola, distribución $H_0$




Si p-valor $< \alpha$, existe evidencia para rechazar $H_0$, es decir, existe evidencia a favor de $H_1$.

## Contrastes individuales

Prueba si un parámetro es significativamente diferente de un cierto valor, $\vartheta$.

- $H_0 : \beta_j = \vartheta$
- $H_1 : \beta_j \neq \vartheta$

$$\text{Bajo } H_0: \quad t = \frac{\hat{\beta}_j - \vartheta}{\text{ee}(\hat{\beta}_j)} \sim t_{n-k-1}$$

Si $|t| > |t_{n-k-1,\alpha/2}|$, existe evidencia para rechazar $H_0$.

**Contraste de significación individual**: Prueba si un parámetro es **significativamente distinto de cero**.

- $H_0 : \beta_j = 0$
- $H_1 : \beta_j \neq 0$

$$\text{Bajo } H_0: \quad t = \frac{\hat{\beta}_j}{\text{ee}(\hat{\beta}_j)} \sim t_{n-k-1}$$

Si $|t| > |t_{n-k-1,\alpha/2}|$, existe evidencia para rechazar $H_0$.

## Contraste F

Prueba simultáneamente múltiples hipótesis (lineales) sobre los parámetros. Hace uso de un modelo no restringido y uno restringido:

- **Modelo no restringido**: Modelo donde se quiere probar la hipótesis.
- **Modelo restringido**: Modelo donde se ha impuesto la hipótesis.

Entonces, viendo los errores, hay:

- $\textbf{SRC}_{\textbf{NR}}$: SRC del modelo no restringido.
- $\textbf{SRC}_{\textbf{R}}$: SRC del modelo restringido.

$$\text{Bajo } H_0: \quad F = \frac{\text{SRC}_\text{R} - \text{SRC}_\text{NR}}{\text{SRC}_\text{NR}} \cdot \frac{n-k-1}{q} \sim F_{q,n-k-1}$$

donde $k$ es el número de parámetros del modelo no restringido (excluyendo la constante) y $q$ es el número de hipótesis lineales a probar.

Si $F > F_{q,n-k-1}$, existe evidencia para rechazar $H_0$.

**Contraste de significación global**: Prueba si todos los parámetros asociados a las $x$'s son **simultáneamente cero**.

- $H_0$: $\beta_1 = \beta_2 = \cdots = \beta_k = 0$
- $H_1$: Al menos un $\beta_j \neq 0 \quad j = 1, \ldots, k$

Simplificando la fórmula para el estadístico $F$:

$$\text{Bajo } H_0: \quad F = \frac{R^2}{1-R^2} \cdot \frac{n-k-1}{k} \sim F_{k,n-k-1}$$

Si $F > F_{k,n-k-1}$, existe evidencia para rechazar $H_0$.

# Intervalos de confianza

El intervalo de confianza al nivel de confianza $(1-\alpha)$:

$$\hat{\beta}_j \pm |t_{n-k-1,\alpha/2}| \cdot \text{ee}(\hat{\beta}_j)$$

# Variables ficticias

Las variables ficticias (o binarias) son usadas para recoger información cualitativa: sexo, estado civil, país, etc.

- Toman **valor 1** en una categoría dada y **0 en el resto**.
- Se usan para analizar y modelar **cambios estructurales** en los parámetros.

Si una variable cualitativa tiene $m$ categorías, sólo hay que incluir $(m-1)$ variables ficticias en un modelo con término constante (incluir $m$ si el modelo no tiene término constante).

## Cambio estructural

El cambio estructural se refiere a los cambios en los valores de los parámetros del modelo producidos por el efecto de diferentes sub-poblaciones. El cambio estructural se puede incluir en el modelo a través de variables ficticias.

La ubicación de las variables ficticias ($D$) es importante:

- **En la constante** (efecto aditivo): Representa la diferencia media entre los valores producidos por el cambio estructural.

$$y = \beta_0 + \delta_1 D + \beta_1 x_1 + u$$

- **En la pendiente** (efecto multiplicativo): Representa la diferencia en el efecto (pendiente) entre los valores producidos por el cambio estructural.

$$y = \beta_0 + \beta_1 x_1 + \delta_1 D \cdot x_1 + u$$

**Contraste de Chow para cambio estructural**. Prueba la existencia de cambio estructural en todos los parámetros del modelo. Es una expresión particular del contraste F, donde $H_0$: No hay cambio estructural (todos $\delta = 0$).

# Cambios de escala

Cambios en las **unidades de medida** de las variables:

- **Endógena**: $y^* = y \cdot \lambda \rightarrow \beta_j^* = \beta_j \cdot \lambda \quad \forall j = 0, \ldots, k$
- **Exógena**: $x_j^* = x_j \cdot \lambda \rightarrow \beta_j^* = \beta_j / \lambda$
- Endógena y exógena **a la vez**: $y^* = y \cdot \lambda$ y $x_j^* = x_j \cdot \lambda \rightarrow \beta_0^* = \beta_0 \cdot \lambda$; $\beta_j^* = \beta_j$.

# Cambios de origen

Cambios en el **origen de medida** de las variables sólo afectan al término constante del modelo:

- **Endógena**: $y^* = y + \lambda \rightarrow \beta_0^* = \beta_0 + \lambda$
- **Exógena**: $x_j^* = x_j + \lambda \rightarrow \beta_0^* = \beta_0 - \lambda\beta_j$

# Multicolinealidad

- **Multicolinealidad perfecta**: Hay variables independientes que son constantes y/o hay una relación lineal exacta entre variables independientes. Se **incumple el tercer (3) supuesto** de MCO.
- **Multicolinealidad aproximada**: Hay variables independientes que son aproximadamente constantes y/o hay una relación lineal aproximada entre variables independientes. **No se incumple ningún supuesto** de MCO, pero hay efectos.

## Consecuencias

- **Multicolinealidad perfecta**: El sistema de ecuaciones de MCO no puede resolverse (infinitas soluciones).
- **Multicolinealidad aproximada**
  - Pequeñas variaciones en la muestra producen grandes variaciones en las estimaciones de MCO.
  - La varianza de los estimadores MCO de las $x$'s que son colineales aumenta, la inferencia de los parámetros es afectada (intervalo de confianza grande).

## Detección

- **Análisis de correlación**: Buscar altas correlaciones entre variables independientes, $|r| > 0.7$.
- **Factor de Inflación de la Varianza (VIF)**: Indica el incremento en $\text{Var}(\hat{\beta}_j)$ debido a la multicolinealidad.

$$\text{VIF}(\hat{\beta}_j) = \frac{1}{1-R_j^2}$$

  donde $R_j^2$ denota el R-cuadrado de una regresión entre $x_j$ y todas las otras $x$.
  - Valores entre 4 y 10: Aviso.
  - Valores $> 10$: Problema serio.

Una característica típica de la multicolinealidad es que los coeficientes de regresión del modelo no son individualmente significativos (por las altas varianzas), pero sí que son conjuntamente significativos.

## Corrección

- Eliminar una de las variables colineales.
- Realizar análisis factorial(u otra técnica de reducción de dimensiones) en las variables colineales.
- Interpretar los coeficientes con multicolinealidad conjuntamente.

# Heterocedasticidad

El término de error $u_i$ no tiene una varianza constante condicionada a las variables explicativas:

$$\text{Var}(u_i \mid x_{1i}, \ldots, x_{ki}) = \sigma_i^2 \neq \sigma^2$$

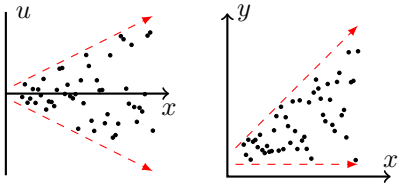
Se **incumple el quinto (5) supuesto** de MCO.

## Consecuencias

- Estimadores MCO son consistentes.
- Estimadores MCO son insesgados.
- MCO ya **no es eficiente**, pero sigue siendo ELI (Estimador Lineal Insesgado).
- La **estimación de la varianza** de los estimadores es **sesgada**: La construcción de intervalos de confianza y contraste de hipótesis no son fiables.

## Detección

- **Gráficos**: Identificar patrones de dispersión en $x$ vs. $u$ ó $x$ vs. $y$.




- **Contrastes**: White, Bartlett, Breusch-Pagan, etc. Generalmente, $H_0$: No heterocedasticidad.

## Corrección

- Usar MCO con un estimador de la matriz de varianzas-covarianzas robusto a la heterocedasticidad (HC), por ejemplo, la propuesta de White.
- Si la estructura de la varianza es conocida, usar Mínimos Cuadrados Ponderados (MCP) o Mínimos Cuadrados Generalizados (MCG):
  - Suponiendo que $\text{Var}(u_i) = \sigma^2 \cdot x_i$, dividir las variables del modelo entre la raíz cuadrada de $x_i$ y aplicar MCO.
  - Suponiendo que $\text{Var}(u_i) = \sigma^2 \cdot x_i^2$, dividir las variables del modelo entre $x_i$ (la raíz cuadrada de $x_i^2$) y aplicar MCO.
- Si la estructura de la varianza es desconocida, hacer uso de Mínimos Cuadrados Ponderados Factibles (MCPF), que estima una posible varianza, divide las variables del modelo entre ella y entonces aplica MCO.
- Nueva especificación del modelo, por ejemplo, transformación logarítmica (reduce la varianza).

# Autocorrelación

Los términos de error $u_t$ y $u_s$ están correlacionados a lo largo de distintos periodos temporales, condicionalmente a las variables explicativas:

$$\text{Corr}(u_t, u_s \mid x_1, \ldots, x_k) \neq 0 \quad \exists t \neq s$$

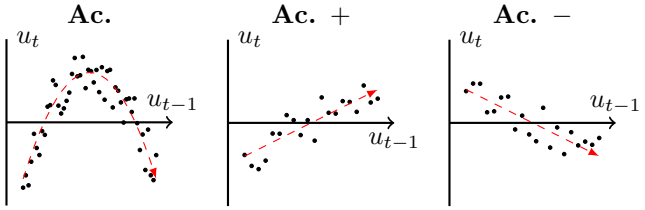
El contexto "natural" de este fenómeno son las series temporales. Se **incumple el sexto (6) supuesto** de MCO.

## Consecuencias

- Estimadores MCO son consistentes.
- Estimadores MCO son insesgados.
- MCO ya **no es eficiente**, pero sigue siendo ELI (Estimador Lineal Insesgado).
- La **estimación de la varianza** de los estimadores es **sesgada**: la construcción de intervalos de confianza y contraste de hipótesis no son fiables.

## Detección

- **Gráficos**: Identificar patrones de dispersión en gráficos $u_{t-1}$ vs. $u_t$ o hacer uso del correlograma.




- **Contrastes**: Durbin-Watson, Breusch-Godfrey, etc. Generalmente, $H_0$: No autocorrelación.

## Corrección

- Usar MCO con un estimador de la matriz de varianzas-covarianzas robusto a la heterocedasticidad y autocorrelación (HAC), por ejemplo, la propuesta de Newey-West.
- Usar Mínimos Cuadrados Generalizados. Suponiendo $y_t = \beta_0 + \beta_1 x_t + u_t$, con $u_t = \rho u_{t-1} + \varepsilon_t$, donde $|\rho| < 1$ y $\varepsilon_t$ es ruido blanco.
  - Si $\rho$ es conocido, crear un modelo cuasi-diferenciado donde $\varepsilon_t$ es ruido blanco y estimarlo por MCO.
  - Si $\rho$ es desconocido, estimarlo, por ejemplo, por el método de Cochrane-Orcutt, crear un modelo cuasi-diferenciado donde $\varepsilon_t$ es ruido blanco y estimarlo por MCO.