# Hoja de Referencia Series Temporales

Por Marcelo Moreno Porras - Universidad Rey Juan Carlos
The Econometrics Cheat Sheet Project

## Conceptos básicos

### Definiciones

**Serie temporal**: Sucesión de observaciones ordenadas en el tiempo con una frecuencia fija.

Dado el formato de una serie temporal:

- **Punto en el tiempo (stock)**: Se registra un único valor para cada período.
- **Agregado (flujo)**: Los valores representan totales o promedios a lo largo del período.
- **Rango/intervalo (OHLC)**: Cada período registra múltiples estadísticas, como *min, max, open, close*.

**Proceso estocástico**: Es una secuencia de variables aleatorias que están indexadas en el tiempo.

### Componentes de una serie temporal

- **Tendencia**: Movimiento general a l/p de una serie.
- **Variaciones estacionales**: Oscilaciones periódicas producidas en un período igual o inferior al año, y pueden ser fácilmente identificadas en diferentes años (usualmente resultado de la climatología).
- **Ciclo**: Oscilaciones periódicas producidas en un periodo mayor al año (son resultado del ciclo económico).
- **Variaciones residuales**: Movimientos que no siguen una oscilación periódica identificable (eventos irreg.)

### Tipos de modelos de series temporales

- **Modelos estáticos**: La relación entre $y$ y $x$ es contemporánea. Conceptualmente:
$$y_t = \beta_0 + \beta_1 x_t + u_t$$
- **Modelos de rezagos distribuidos**: La relación entre $y$ y $x$ no es contemporánea. Conceptualmente:
$$y_t = \beta_0 + \beta_1 x_t + \beta_2 x_{t-1} + \cdots + \beta_s x_{t-s} + u_t$$
El efecto acumulado a largo plazo en $y$ cuando $\Delta x = 1$:
$$\beta_1 + \beta_2 + \cdots + \beta_s$$
- **Modelos dinámicos**: Introduce rezagos de la variable dependiente. Conceptualmente:
$$y_t = \beta_0 + \beta_1 y_{t-1} + \cdots + \beta_s y_{t-s} + u_t$$
- Combinación de lo anterior, como modelos de rezagos distribuidos racionales (rezagos distribuidos + dinámicos).

## Supuestos y propiedades

### Supuestos MCO en series temporales

**Supuestos Gauss-Markov** extendidos para series temporales:

t1. **Linealidad de parámetros y dependencia débil**:
   a. $y_t$ debe ser una función lineal de los $\beta$'s.
   b. El proceso estocástico $\{(x_t, y_t) : t = 1, 2, \ldots, T\}$ es estacionario y débilmente dependiente.

t2. **No colinealidad perfecta**:
   - No hay variables independientes que sean constantes: $\text{Var}(x_{jt}) \neq 0 \quad \forall j = 1, \ldots, k$
   - No hay una relación lineal exacta entre variables independientes.

t3. **Media condicional cero y correlación cero**:
   a. No hay variables relevantes fuera del modelo: $\text{Cov}(x_{jt}, u_t) = 0 \quad \forall j = 1, \ldots, k \rightarrow$ **exogeneidad**
   b. No hay errores sistemáticos: $\text{E}(u_t \mid \text{X}) = \text{E}(u_t \mid \ldots, \text{x}_{t+1}, \text{x}_t, \text{x}_{t-1}, \ldots) = 0 \quad \forall t$ $\rightarrow$ **exogeneidad estricta** (cumple 3a)

t4. **Homocedasticidad**: La variabilidad del término de error es igual para todos los niveles $x$:
$$\text{Var}(u_t \mid x_{1t}, \ldots, x_{kt}) = \sigma^2 \quad \forall t = 1, \ldots, T$$

t5. **No autocorrelación**: Los errores no contienen información sobre otros errores:
$$\text{Corr}(u_t, u_s \mid x_1, \ldots, x_k) = 0 \quad \forall t \neq s$$

t6. **Normalidad**: Los errores son independientes e idénticamente distribuidos: $u_t \overset{iid}{\sim} \mathcal{N}(0, \sigma^2)$

t7. **Tamaño de datos**: El número de observaciones disponibles debe ser mayor a $(k+1)$ parámetros a estimar.

### Propiedades asintóticas de MCO

Bajo los supuestos Gauss-Markov y el Teorema Central del Límite (TCL):

- De t1 a t3a: MCO es **consistente**: $\text{plim}(\hat{\beta}_j) = \beta_j$
- De t1 a t3b: MCO es **insesgado**: $\text{E}(\hat{\beta}_j) = \beta_j$
- De t1 a t5: **normalidad asintótica** de estimadores: $\hat{\beta}_j \underset{a}{\sim} \mathcal{N}(\beta_j, \text{Var}(\hat{\beta}_j))$
- De t1 a t5: **estimador insesgado** de $\sigma^2$: $\text{E}(\hat{\sigma}^2) = \sigma^2$
- De t1 a t5: MCO es MELI (Mejor Estimador Lineal Insesgado, BLUE en inglés) or **eficiente**.
- De t1 a t6: contrastes de hipótesis e intervalos de confianza son fiables.

**Regresión espuria**: Ocurre cuando se encuentra una relación estadísticamente significativa—pero falsa—entre series indep. no estacionarias (p.e., debido a tendencias compartidas), a pesar de que no existe un vínculo causal real. Esto **incumple el primer supuesto (t1b)** de MCO.

## Tendencia y estacionalidad

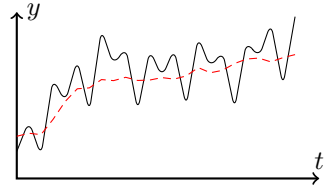
### Tendencia

Dos series temporales pueden tener la misma (o contraria) tendencia, lo que lleva a altos niveles de correlación. Esto provoca una falsa apariencia de causalidad; el problema es **correlación espuria**. Dado el modelo:
$$y_t = \beta_0 + \beta_1 x_t + u_t$$
donde:
$$y_t = \alpha_0 + \alpha_1 \text{Tendencia} + v_t$$
$$x_t = \gamma_0 + \gamma_1 \text{Tendencia} + w_t$$
Añadir una tendencia al modelo puede resolver el problema:
$$y_t = \beta_0 + \beta_1 x_t + \beta_2 \text{Tendencia} + u_t$$
Una tendencia puede ser lineal o no lineal (cuadrática, cúbica, exponencial, etc.)

Otra manera, es hacer uso del **filtro Hodrick-Prescott** y extraer la tendencia y el componente cíclico.

### Estacionalidad

Una serie temporal puede manifestar estacionalidad. Esto es, que está sujeta a variaciones estacionales o patrones climáticos.




Por ejemplo, el PIB es mayor en verano y menor en invierno (serie ajustada estacionalmente en discontinuo).

- La regresión de series temporales que presentan estacionalidad puede conducir a **resultados espurios**.

Existen diferentes métodos de **ajuste estacional**:

a. Incluir variables estacionales binarias en el modelo. Por ejemplo, serie trimestral ($Sq_t$ son variables binarias):
$y_t = \beta_0 + \beta_1 S2_t + \beta_2 S3_t + \beta_3 S4_t + \beta_4 x_{1t} + \cdots + \beta_k x_{kt} + u_t$
b. Ajustar estacionalmente las variables y luego realizar la regresión con las variables ajustadas.
c. Tomar diferencias estacionales ($s$ es el período estacional):
$$\Delta_s y_t = y_t - y_{t-s}$$
d. Aplicar el ajuste **X-13ARIMA-SEATS**.

# Autocorrelación

Los términos de error $u_t$ y $u_s$ están correlacionados a lo largo de distintos periodos temporales, condicionalmente a las variables explicativas. Se **incumple el quinto (t5) supuesto** OLS.

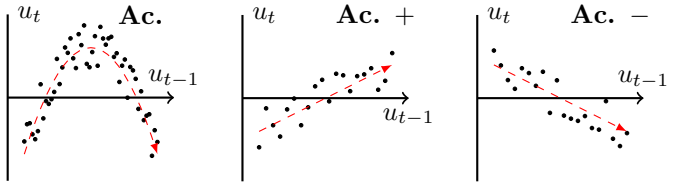
$$\text{Corr}(u_t, u_s \mid x_1, \ldots, x_k) \neq 0 \quad \exists t \neq s$$

## Consecuencias

- Estimadores MCO son consistentes.
- Estimadores MCO son insesgados.
- MCO ya **no es eficiente**, pero sigue siendo ELI (Estimador Lineal Insesgado).
- La **estimación de la varianza** de los estimadores es **sesgada**: la construcción de intervalos de confianza y contraste de hipótesis no son fiables.

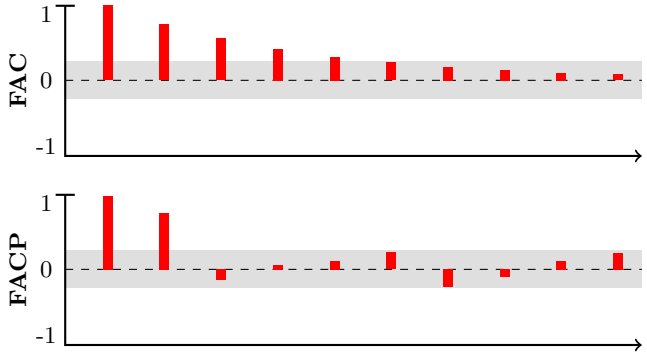
## Detección

**Gráficos de dispersión**: Buscar patrones en $u_{t-1}$ vs. $u_t$.




**Correlograma**: Función de autocorrelación (FAC) y el FAC parcial (FACP).

- Eje Y: correlación.
- Eje X: núm. de retardo.
- Área gris: $\pm 1.96/T^{0.5}$




- **Proceso MA**$(q)$. FAC: los $q$ primeros coeficientes son significativos, el resto se anulan bruscamente. FACP: decrecimiento exponencial rápido u ondas sinusoidales.
- **Proceso AR**$(p)$. FAC: decrecimiento exponencial rápido u ondas sinusoidales. FACP: los $p$ primeros coeficientes son significativos, el resto se anulan bruscamente.
- **Proceso ARMA**$(p, q)$. FAC y FACP: los coeficientes no se anulan bruscamente y presentan un decrecimiento rápido.

Si los coeficientes de la FAC no decaen rápidamente, hay claro indicio de falta de estacionariedad en media.

**Contrastes**:

Suponiendo que $u_t$ sigue un proceso AR(1):

$$u_t = \rho_1 u_{t-1} + \varepsilon_t$$

donde $\varepsilon_t$ es ruido blanco.

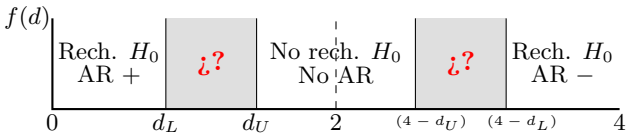
- **Prueba t AR(1)**:
  - Regresores exógenos.
  - $H_0$: No autocorrelación.
  - $H_1$: Autocorrelación de orden uno, AR(1).

$$\text{Bajo } H_0: \quad t = \frac{\hat{\rho}_1}{\text{ee}(\hat{\rho}_1)} \sim t_{T-k-1}$$

- **Estadístico Durbin-Watson**:
  - Regresores exógenos y normalidad de residuos.
  - $H_0$: No autocorrelación.
  - $H_1$: Autocorrelación de orden uno, AR(1).

$$\text{Bajo } H_0: \quad d = \frac{\sum_{t=2}^{T}(\hat{u}_t - \hat{u}_{t-1})^2}{\sum_{t=1}^{T}\hat{u}_t^2} \approx 2 \cdot (1 - \hat{\rho}_1)$$

donde $0 \leq d \leq 4$.




- **h de Durbin**:
  - Modelos dinámicos.
  - $H_0$: No autocorrelación.
  - $H_1$: Autocorrelación de orden uno, AR(1).

$$\text{Bajo } H_0: \quad h = \hat{\rho} \cdot \sqrt{\frac{T}{1 - T \cdot \widehat{\text{Var}}(\hat{\beta}_{\text{lag}})}} \underset{a}{\sim} \mathcal{N}(0,1)$$

- **Prueba Breusch-Godfrey**:
  - MA$(q)$: $u_t = \varepsilon_t - m_1\varepsilon_{t-1} - \cdots - m_q\varepsilon_{t-q}$
  - AR$(p)$: $u_t = \rho_1 u_{t-1} + \cdots + \rho_p u_{t-p} + \varepsilon_t$
  - $H_0$: No autocorrelación.
  - $H_1$: Autocorrelación de orden $q$ o $p$.

$$\text{Bajo } H_0: \quad T \cdot R^2_{\hat{u}_t} \underset{a}{\sim} \chi^2_{q \text{ ó } p}$$

- **Prueba Ljung-Box Q**:
  - $H_0$: No autocorrelación hasta retardo $h$.
  - $H_1$: Al menos una autocorrelación hasta retardo $h$.

$$\text{Bajo } H_0: \quad Q_{LB} = T(T+2)\sum_{k=1}^{h}\frac{\hat{\rho}_k^2}{T-k} \underset{a}{\sim} \chi^2_h$$

## Corrección

- Usar MCO con un estimador de la matriz de varianzas-covarianzas **robusto a la heterocedasticidad y autocorrelación** (HAC), por ejemplo, la propuesta de **Newey-West**.
- Usar **Mínimos Cuadrados Generalizados** (MCG). Suponiendo $y_t = \beta_0 + \beta_1 x_t + u_t$, con $u_t = \rho u_{t-1} + \varepsilon_t$, donde $|\rho| < 1$ y $\varepsilon_t$ es ruido blanco.
  - Si $\rho$ es **conocido**, usar **modelo cuasi-diferenciado**:

$$y_t - \rho y_{t-1} = \beta_0(1-\rho) + \beta_1(x_t - \rho x_{t-1}) + u_t - \rho u_{t-1}$$
$$y_t^* = \beta_0^* + \beta_1' x_t^* + \varepsilon_t$$

    donde $\beta_1' = \beta_1$; y estimarlo por MCO.
  - Si $\rho$ es **desconocido**, estimarlo—por ejemplo—el **método iterativo de Cochrane-Orcutt**:
    1. Obtener $\hat{u}_t$ del modelo original.
    2. Estimar $\hat{u}_t = \rho\hat{u}_{t-1} + \varepsilon_t$ y obtener $\hat{\rho}$.
    3. Crear un modelo cuasi-diferenciado:

$$y_t - \hat{\rho} y_{t-1} = \beta_0(1-\hat{\rho}) + \beta_1(x_t - \hat{\rho} x_{t-1}) + u_t - \hat{\rho} u_{t-1}$$
$$y_t^* = \beta_0^* + \beta_1' x_t^* + \varepsilon_t$$

       donde $\beta_1' = \beta_1$; y estimarlo por MCO.
    4. Obtener $\hat{\beta}_0 = \hat{\beta}_0^*/(1-\hat{\rho})$
    5. Computar $\hat{u}_t = y_t - (\hat{\beta}_0 + \hat{\beta}_1' x_t)$.
    6. Repetir desde el paso 2. El algoritmo termina cuando los parámetros estimados varían muy poco entre iteraciones.
- Si no se arregla, buscar **fuerte dependencia** en la serie.

# Suavizado exponencial

Dado $\{y_t\}$, la serie suavizada $\{f_t\}$:

$$f_t = \alpha y_t + (1-\alpha) f_{t-1}$$

donde $0 < \alpha < 1$ es el factor de suavizado y $f_0 = y_0$.

# Predicciones

Dos tipos de predicciones:

- Valor medio de $y$ para un valor específico de $x$.
- Valor individual de $y$ para un valor específico de $x$.

**U de Theil** - compara los resultados pronosticados con los de la previsión con datos históricos mínimos.

$$U = \sqrt{\frac{\sum_{t=1}^{T-1}\left(\frac{\hat{y}_{t+1} - y_{t+1}}{y_t}\right)^2}{\sum_{t=1}^{T-1}\left(\frac{y_{t+1} - y_t}{y_t}\right)^2}}$$

- $< 1$: La predicción es mejor que adivinar.
- $= 1$: La predicción es tan buena como adivinar.
- $> 1$: La predicción es peor que adivinar.

# Estacionariedad

La estacionariedad permite reconocer relaciones—inalteradas en el tiempo—entre variables.

- **Proceso estacionario** (estacionariedad estricta): La distribución de probabilidad conjunta del proceso permanece inalterada al desplazarse $h$ periodos.
- **Proceso no estacionario**: Por ejemplo, una serie con tendencia, donde al menos la media cambia con el tiempo.
- **Proceso estacionario en covarianza**: Es una forma más débil de estacionariedad:
  - $\mathrm{E}(x_t)$ es constante.
  - $\mathrm{Var}(x_t)$ es constante.
  - Para cualquier $t, h \geq 1$, $\mathrm{Cov}(x_t, x_{t+h})$ depende sólo de $h$, no de $t$.

# Dependencia débil

La dependencia débil reemplaza el supuesto de muestreo aleatorio en series temporales.

- Un proceso estacionario $\{x_t\}$ es **débilmente dependiente** cuando $x_t$ y $x_{t+h}$ son casi independientes a medida que $h$ aumenta sin límite.
- Un proceso estacionario en covarianza es **débilmente dependiente** si la correlación entre $x_t$ y $x_{t+h}$ tiende a 0 lo suficientemente rápido cuando $h \to \infty$ (no están asintóticamente correlacionados).

La mayoría de procesos estacionarios débilmente dependientes son **integrados de orden cero**, I(0). Ejemplos:

- **Media móvil**: $\{x_t\}$ es una media móvil de orden $q$, MA($q$):
  $$x_t = e_t + m_1 e_{t-1} + \cdots + m_q e_{t-q}$$
  donde $\{e_t : t = 0, 1, \ldots, T\}$ es una secuencia *i.i.d.* con media cero y varianza $\sigma_e^2$.
- **Proceso autorregresivo**: $\{x_t\}$ es un proceso autorregresivo de orden $p$, AR($p$):
  $$x_t = \rho_1 x_{t-1} + \cdots + \rho_p x_{t-p} + e_t$$
  donde $\{e_t : t = 1, 2, \ldots, T\}$ es una secuencia *i.i.d.* con media cero y varianza $\sigma_e^2$.
  **Condición de estabilidad**: Si todas las raíces $z$ de la ecuación característica $1 - \rho_1 z - \cdots - \rho_p z^p = 0$ satisfacen $|z| > 1$, entonces $\{x_t\}$ es estable y débilmente dependiente AR($p$). Para AR(1), la condición es: $|\rho_1| < 1$.
- **Proceso ARMA**: Es una combinación de los dos anteriores; $\{x_t\}$ es un ARMA($p, q$):
  $x_t = e_t + m_1 e_{t-1} + \cdots + m_q e_{t-q} + \rho_1 x_{t-1} + \cdots + \rho_p x_{t-p}$

# Raíces unitarias

Un proceso es integrado de orden $d$, I($d$), si al aplicar diferencias $d$ veces hace al proceso estacionario.
Cuando $d \geq 1$, se dice que el proceso tiene **raíz unitaria**. Un proceso tiene una raíz unitaria cuando no se cumple la condición de estabilidad (hay raíces en el círculo unitario).

## Dependencia fuerte

Generalmente, las series económicas son fuertemente persistentes. Algunos ejemplos de **raíz unitaria** I(1):

- **Paseo aleatorio**: Un proceso AR(1) con $\rho_1 = 1$.
  $$y_t = y_{t-1} + e_t$$
  donde $\{e_t : t = 1, 2, \ldots, T\}$ es una secuencia *i.i.d.* con media cero y varianza $\sigma_e^2$.
- **Paseo aleatorio con deriva**: Un proceso AR(1) con $\rho_1 = 1$ y una constante.
  $$y_t = \beta_0 + y_{t-1} + e_t$$
  donde $\{e_t : t = 1, 2, \ldots, T\}$ es una secuencia *i.i.d.* con media cero y varianza $\sigma_e^2$.

## Contrastes de raíz unitaria

| Contraste | $H_0$ | Rechazar $H_0$ |
|---|---|---|
| ADF | I(1) | $\tau <$ Valor crítico |
| KPSS | I(0) nivel | $\eta_\mu >$ Valor crítico |
| KPSS | I(0) tendencia | $\eta_\tau >$ Valor crítico |
| Phillips-Perron | I(1) | Z($\tau$) < Val. crítico |
| Zivot-Andrews* | I(1) | $t_{\min} <$ Valor crítico |

* Prueba en presencia de quiebres estructurales.

## De raíz unitaria a dependencia débil

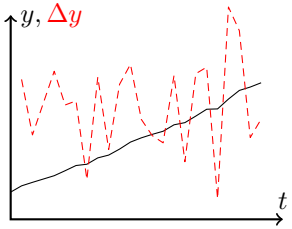
Integrado de **orden uno**, I(1), significa que **la primera diferencia** del proceso es **débilmente dependiente** ó I(0) (y usualmente, estacionaria). Sea $\{y_t\}$ un paseo aleatorio:

$$\Delta y_t = y_t - y_{t-1} = e_t$$

donde $\{e_t\} = \{\Delta y_t\}$ es *i.i.d.*

Nota:

- La primera diferencia suele eliminar tendencias.
- Los logaritmos suelen estabilizar la varianza.




Cuando una serie I(1) es estrictamente positiva, a menudo se utilizan logaritmos antes de diferenciar para aproximar cambios porcentuales:

$$\Delta \log(y_t) = \log(y_t) - \log(y_{t-1}) \approx \frac{y_t - y_{t-1}}{y_{t-1}}$$

## Ergodicidad

Un proceso estrictamente estacionario $\{y_t\}$ es **ergódico** si los promedios temporales convergen a sus promedios poblacionales (esperanzas). Esto suele garantizarse mediante una **mezcla fuerte** (strong mixing), que implica independencia asintótica de eventos lejanos.

$$\tfrac{1}{T}\textstyle\sum_{t=1}^{T} y_t \underset{a}{\to} \mathrm{E}(y_t)$$

Sin ello, los momentos muestrales pueden no reflejar los momentos poblacionales. Los estimadores son inconsistentes.

# Cointegración

Dos series I(1) están **cointegradas** si una combinación lineal de ellas es I(0). Una regresión entre ellas no es espuria, sino que refleja una relación de **largo plazo**. Las variables cointegradas comparten una tendencia estocástica común. Por ejemplo, $\{x_t\}$ y $\{y_t\}$ son I(1), pero $y_t - \beta x_t = u_t$ donde $\{u_t\}$ es I(0). ($\beta$ es el parámetro cointegrador).

## Contraste de cointegración

Contraste Engle-Granger:

1. Estimar $y_t = \alpha + \beta x_t + u_t$ y obtener $\hat{u}_t$.
2. Realizar el ADF sobre $\hat{u}_t$ con una distribución especial. El resultado del contraste es equivalente a:
   - $H_0$: $\hat{u}_t \sim$ I(1) → No hay cointegración.
   - $H_1$: $\hat{u}_t \sim$ I(0) → Existe cointegración.

   si el estadístico de contraste < valor crítico, rechazar $H_0$.

# Heterocedasticidad en series temp.

Afecta al **supuesto t4**, lo que lleva a que **MCO no sea eficiente**.
Usar contrastes como el Breusch-Pagan o White, donde $H_0$: No heterocedasticidad. Para que los contrastes funcionen, no ha de existir **autocorrelación**.

## ARCH

Un modelo de heteroced. condicional autorreg. (ARCH) se usa para analizar heterocedasticidad condicional dinámica, donde los errores al cuadrado siguen un proceso AR($p$).
Dado el modelo: $y_t = \beta_0 + \beta_1 z_t + u_t$, con errores no correlacionados serialmente satisfaciendo $\mathrm{E}(u_t \mid \mathcal{F}_{t-1}) = 0$, una varianza del error ARCH(1) se especifica como :

$$\sigma_t^2 = \mathrm{Var}(u_t \mid \mathcal{F}_{t-1}) = \mathrm{E}(u_t^2 \mid \mathcal{F}_{t-1}) = \alpha_0 + \alpha_1 u_{t-1}^2$$

donde $\alpha_0 > 0$ y $0 \leq \alpha_1 < 1$ garantiza la positividad y la estacionariedad de la covarianza.